TACL 后续研究方案书

固定预算下，在线学习收益与多标签正例曝光约束的联合课程

研究目标：以 ICD 完整标签编码为主线，TCM 单标签分类验证迁移；使用约48GB单卡资源。

本方案提出可证伪的调度机制与实验协议。文献结论、已完成的仓库整理和待实施研究分别标识；当前没有新方法的训练结果。

建议以一个可测量、可证伪的课程调度问题作为论文贡献：在相同编码 token 预算下，利用在线收益代理选择训练记录，同时限制多标签正例曝光的长期不足。贡献应落在多标签共现、有限预算、目标风险一致性和覆盖可行性的耦合，而不是单独宣称首次标签感知、首次动态课程或首次使用 EMA。

首先复现原TACL与同骨干随机训练，再检验收益调度、覆盖约束及动态债务反馈的增量作用。无收益时的覆盖版本恒等于静态参考分布，作为等价性检查复用计算，不能当作独立方法。主实验使用显式重要性权重保持自然经验风险；忠实TACL与同风险adaptation分表，改变目标风险的重平衡版本另列。所有性能提升、耗时和显存目前均为待验证假设。

来源：TACL arXiv 2510.15269v2；代码基线 6730635。
文献核验日期：2026-10-20。

阅读导航

1. 研究问题、研究边界与三条假设

2. 相关工作与可以主张的新意

3. 数据、任务适配与不可泄漏的信息边界

4. 固定预算、符号与优化目标

5. 可行参考分布、探索与正例覆盖债务

6. 在线收益代理、刷新间隔与陈旧状态

7. 联合课程优化与可行性

8. 采样偏差、风险选择与理论声明边界

9. 伪码、接口、日志与 checkpoint

10. 单卡48GB资源路径与复杂度

11. 预注册实验矩阵与公平比较

12. 指标、统计、不确定性与OOD

13. 第二阶段：知识、检索和LLM证据备选

14. 成功、停止标准和研究交付

附录：默认配置、证据状态、参考文献及配套实验文件。

1. 研究问题、研究边界与三条假设

把研究问题从更换编码器收敛为：训练预算有限时，应如何决定下一批记录，以及如何避免尾标签在选择过程中失去正例曝光。

原 TACL 将训练样本划分难度并自适应推进课程，覆盖 ICD 编码、再入院预测和 TCM 证候等任务。仓库中同时存在 APW、质心距离、KMeans 与多种实验脚本。后续工作必须区分论文算法、代码变体和可运行复现入口；不能先合并变体再把所得结果当作原论文复现。

相关证据 [1]

本研究保留成熟领域编码器与标签预测头。首轮不添加图网络、检索重排或 LLM 在线教师。方法是否有效，应由同骨干、同数据划分、同目标风险、同预算的比较证明。英文 ICD 多标签分类承担主要发现；中文 TCM 任务检验同一个调度器是否能够跨语言、跨输出形式复用。

假设	可检验命题	主要证据	反证条件
H1：收益与覆盖互补	完整方法相较收益独用、静态参考r和固定覆盖下界有增量，减少尾标签曝光债务并提高尾标签F1；u=0版本与r等价，合并验证。	固定预算主矩阵、固定/动态覆盖消融、覆盖-性能曲线。	完整方法与静态参考或固定覆盖无稳定差异，或收益来自改变训练目标。
H2：效率而非预算换分	同编码 token 预算下达到更高性能，或达到基线性能所需 token/墙钟更少。	25%/50%/100%预算检查点及达到目标分数的成本。	只在增加训练 token、离线打分成本或延长训练后获益。
H3：任务间机制可迁移	在预注册的 TCM 配置中，同一覆盖-收益机制保持方向一致，无须重设计课程。	ICD 与 TCM 分别调有限超参、共享定义与消融。	只能为每个任务定制不同评分器或依赖不可获得的医学本体。

H1-H3 是研究假设，不是结果。只有实际运行与统计评估后才能使用“提升”“节省”或“泛化成功”等结论。若主矩阵否定 H1，优先归因收益估计、覆盖约束或优化目标，不追加多种大模型模块掩盖失败。

2. 相关工作与可以主张的新意

已有工作分别研究了学习进展、标签多样性、层次课程、长尾损失和动态数据代理；新意应通过对这些因素的受控比较建立。

Graves 等已用学习进展奖励驱动自动课程；SPMLD 已显式使用实例-标签权重与标签多样性，避免只学习容易标签；HiCu 利用 ICD 输出标签树从粗到细构造课程。因此“动态”“标签感知”“保护多样性”不能分别作为本工作的首次贡献。

相关证据 [2]、[4]、[5]

ADO 的正式发表状态是 ICLR 2025，其 2024 arXiv 版本不是最终书目状态。ADO 在线估计数据域学习潜力并调整混合，说明“免代理模型的在线收益分配”已有直接先行工作。Data Agent 已发表于 ICML 2026，使用随模型训练共演化的选择策略及复合奖励，因此不能将端到端动态数据选择笼统写作研究空白。

相关证据 [15]、[16]

InfoBatch已发表于ICLR2024：它维护逐样本loss，以均值为阈值随机裁剪部分低loss样本，对保留下来的低loss样本重标梯度，并在末期恢复全量训练。因此本文不能把动态loss选样、梯度期望校正或无需独立教师本身当作新贡献。区别须落在多标签实际正例曝光、始终可行的债务下界、最终采样分布和固定成本的联合约束；InfoBatch适配版必须进入同风险主比较。

相关证据 [21]

BLS用样本参与批次的平均loss条件EMA，估计平滑的loss贡献；作者arXiv标注CVPR2026 accepted，本次未独立核实CVF收录页。它与本文EMA的共同点是缓存时间信号，差别是BLS估计loss水平，本文使用按更新间隔归一的loss下降速率，后者仍只是观测收益代理。不能仅凭换成EMA或解释为低通滤波宣称novelty。采用BLS取分加同一InfoBatch适配器可分离评分与调度。

相关证据 [22]

候选贡献是：以多标签正例曝光为可测量资源，在一个具有显式可行参考分布、探索下界、成本限制和重要性校正的采样问题中耦合覆盖债务与在线收益代理。相较 SPMLD 的多样性正则，本方案约束可解释的正例曝光；相较 HiCu 的输出粒度课程，本方案调整输入记录；相较 ADO 的互斥数据域，本方案处理同一记录对多个标签同时贡献曝光；相较 Data Agent，本方案不额外训练策略网络，强调可行性、目标风险与低开销。

上述差异是可防守的研究定位，不等于穷尽性 novelty 证明。投稿前仍须复核同年后续版本，报告已检索的时间边界，并避免把“未检索到”写成“不存在”。2025 年 CD-GTMLL 预印本利用稀有标签与预测分歧的动态奖励，也限制了“尾标签探索”这一宽泛主张。

相关证据 [20]

- 必须证明：优势不是仅由逆频率过采样带来。
- 必须证明：优势不是删除长文本、降低输入覆盖或增加预处理成本带来。
- 必须证明：优势不是阈值、患者划分、损失函数或早停准则不同带来。
- 可以提交的理论内容：参考分布始终可行、探索下界对应的权重上界、采样梯度的条件无偏性。不能预先承诺深度网络全局收敛或确定的尾类 F1 提升。

3. 数据、任务适配与不可泄漏的信息边界

仅对已获授权的本地训练数据构造统计；验证集负责模型选择与校准，测试集在方案冻结后评估。

ICD 主线优先保持原项目现有 MIMIC 数据与 ICD 版本，以明确评价相较 TACL 的改进。Top-50 适合调试，但标签已被频次截断，不能独立支持极端长尾结论。主结论必须至少覆盖一个完整标签设置。若授权和数据齐备，再增加 MIMIC-IV ICD-10；ICD-9 与 ICD-10 分别训练、分别报告，不把简单代码映射当作无缝跨版本迁移。

相关证据 [8]、[9]

数据清单记录原始版本、许可前提、文档 ID、患者或入院组 ID、来源、划分哈希、训练标签表及计数、文本长度分布、截断比例与排除原因。标签词表只能由训练集和预先允许的官方本体确定；仅在测试中出现的标签报告为不可训练标签，不从测试频次回填课程。相同患者的多份记录与文本近重复均需审计，不能仅随机拆分行。

TCM 采用项目既有148类单标签证候任务：当前入口读取JSONL的TEXT与整数LABEL，模型使用CrossEntropyLoss。将LABEL转换为one-hot的正例关联矩阵，课程层接收相同的样本ID、正标签索引、成本和观测损失；中文分词器、预测头和CE由任务适配器负责。若未来新增多标签证候数据，应作为新任务另立协议，不修改首轮定义。病案/患者标识若缺失，必须明确报告划分审计的限制；没有医学层次时不人为构造TCM本体。

信息	可用于训练课程	可用于模型选择	禁止用途
训练标签/训练损失/训练长度	是；含频次、共现与曝光状态	是	不得混入其他划分的计数
开发集标签和指标	不逐记录进入课程；仅全局超参选择	是；选择检查点与阈值	不得针对开发记录调整采样
测试标签/测试误差	否	否	不得选择覆盖阈值、难度、早停或阈值
描述/同义词/祖先知识	第二阶段允许；固定来源与版本	只调预注册少量参数	不得用测试答案合成训练guideline

公开代码与公开可申请数据并非无限制可分发。MIMIC 需要合格访问与协议；文献提供的证据标注也不能脱离原数据权限使用。本轮不下载临床原始数据，不尝试访问受限病案，不调用外部 LLM 分析患者文本。

4. 固定预算、符号与优化目标

先定义预算、损失与采样单位，再讨论课程；否则不同方法可能在不同任务上竞争。

设训练集有 N 份记录，A∈{0,1}^{L×N} 为正例关联矩阵，A_li=1 表示记录 i 含标签 l；只对训练集中至少出现一次的标签建立覆盖约束。同一记录可同时增加多个标签曝光。n_l=Σ_i A_li。TCM 单标签只是每列恰有一个 1 的特例。训练抽样有放回；这里的曝光是记录实际进入一次训练前向/反向，而不是记录被索引、被检索或出现在候选池。

公式 1

$$R_\pi(\theta)=\sum_{i=1}^{N}\pi_i\ell_i(\theta),\quad \pi_i=1/N$$

主实验固定自然经验风险。改变目标分布的实验必须另列。

ICD 的训练风险损失采用同骨干统一的完整标签 BCE；单标签 TCM 用 CE。ASL/DBL 是额外损失对照，在同一种损失内部比较采样器。本文的难度观测可以对正负项做平衡，防止数千个容易负标签淹没信号，但难度观测不是优化风险本身。不得把评分函数悄悄当作训练损失。

公式 2

$$c_i=C\left\lceil\frac{\min(T_i,T_{\max})}{C}\right\rceil,\quad \sum_{s=1}^{S}c_{i_s}\le B$$

预算以固定长度编码块的实际输入 token 计数，包含块内 padding。

C 是统一分块长度，T_max 是统一截断上限。相同记录在相同配置下有相同可预先确定的编码成本；不采用随批动态 padding 的含糊“有效 token”近似比较。若未来改用动态 padding，必须同时记录非 padding

与实际编码 token，并重新定义成本约束。单卡显存限制的是微批；梯度累积不应改变记录级成本计数。

预注册 B100=10×Σ_i c_i，B25/B50 分别为其 25%/50%；warmup、原 TACL 离线难度训练与额外重打分的编码 token 都计入方法总预算。先用1个种子筛查所有主方法，再以相同累计预算扩展到3个种子。10次自然遍历是设计默认值，不是已测最优训练长度；如前置复现发现严重不足，只能在查看测试前统一修改并记录版本。

公式 3

$$m_t = \min\{16, \lfloor B_{\text{remaining}}/c_{\max} \rfloor\}$$

有效批大小在抽样之前由历史剩余预算决定；微批1并累积m_t条。

当m_t=0时停止；否则从当前q独立有放回抽恰好m_t条，按实际m_t而非固定16求平均。最坏总成本m_t*c_max不超过剩余预算，因此不拒绝已抽记录、不按短记录重归一化，也不使批大小依赖本批抽样结果。训练后记录实际成本，终止时未使用预算<c_max。所有方法使用相同规则；曲线按实际累计token对齐，墙钟另测。

5. 可行参考分布、探索与正例覆盖债务

参考分布同时承担可行性证据、尾标签探索来源和重要性权重下界；不把“每批覆盖所有尾标签”当作可实现要求。

公式 4

$$r_i = (1-\eta)/N + \eta \sum_{l=1}^{L} \frac{1}{L} \frac{A_{li}}{n_l}, \quad 0 \le \eta < 1$$

先均匀抽训练标签，再均匀抽该标签的正例，最后与自然记录分布混合。

Σ_i r_i=1，因为每个标签条件分布都归一化；r_i≥(1−η)/N，因此所有训练记录保持支持。多标签记录可能因服务多个稀有标签获得更高 r_i，这是显式定义的参考分布性质，不是假设标签互斥。只使用训练支持集；n_l=0 的标签既不能被抽到正例，也不纳入可行覆盖目标。

公式 5

$$f_l = \sum_i A_{li} r_i, \quad b_l^0 = \kappa f_l, \quad \bar{c} = \sum_i r_i c_i$$

覆盖下界取自一个真实可抽样分布；成本上界也取自同一分布。

默认 η=0.5、κ=0.8。这里 f_l 是每次记录抽样的正例命中概率，既不是目标临床患病率，也不是部署时预测先验。若同时对所有标签设定任意相同的最低比例，稀有标签之间的共现与预算成本可能令问题不可行；从 r 构造目标直接消除了这一风险。

公式 6

$$E_l(S) = \sum_{s=1}^{S} A_{li_s}, \quad D_l(S) = [S b_l^0 - E_l(S)]_+$$

曝光 E 来自实际消费记录；债务 D 是相对基础覆盖目标的实际不足。

公式 7

$$b_l(t) = \min\{f_l,\ b_l^0 + D_l(S_t)/H\}$$

用债务提升后续期望覆盖需求，且不超过参考分布可服务的概率。

默认 H=N 个记录抽样，作为债务修复时间尺度；这是名义窗口，不要求每个 epoch 中每条记录恰好一次。b_l(t)≤f_l 保证 r 在所有刷新时刻可行。债务大时可接近参考分布的服务率；永久预算耗尽时仍可能存在随机债务，不能把期望约束宣称为有限样本的确定性覆盖保证。对极少标签应显示实际曝光次数及置信区间，不能只给百分比。

公式 8

$$q_{t,i} \geq \varepsilon r_i, \quad q_t = \varepsilon r + (1-\varepsilon)p_t, \quad p_t \in \Delta_N$$

探索属于最终采样分布；必须在该最终分布上检查所有约束。

默认 ε=0.2，整个训练期保持不为零。探索为长期未刷新的记录重新提供观测，避免评分自我强化。若先约束 p、再加上探索，或加上长度桶后再次任意归一化，最终 q 可能破坏覆盖和成本约束；实现时检查的对象始终是最终实际抽样分布。

6. 在线收益代理、刷新间隔与陈旧状态

收益是当前模型训练动态的代理量，不是已证明的样本因果效用；它应便宜、可审计且在不同曝光频率间可比较。

每条记录保存最近一次训练前向的评分损失v_i、观测时刻t_i、EMA速率g_i、观测次数k_i。第一次出现时初始化v_i与t_i，令g_i=0；第二次不同更新步观测后才估计下降速率。同一步重复ID只对EMA评分取平均合并，避免零时间间隔；训练损失、重要性权重、成本以及E/S曝光仍保留每次实际消费的重数。

公式 9

$$v_i = \tfrac{1}{2}\mathrm{mean}_{l:A_{il}=1}\mathrm{BCE}_{il} + \tfrac{1}{2}\mathrm{mean}_{l\in\mathcal{N}_i}\mathrm{BCE}_{il}$$

ICD 评分对正例和固定负例子集平衡，避免负标签数量决定难度。

每条记录的负例集合 N_i 从训练标签词表中按 seed 与 sample_id 的固定哈希选择至多32个负标签，所有方法共享。记录无正标签时评分只取负项；无可用负标签时只取正项。TCM 单标签评分使用真实 CE。评分由 detached 的未乘重要性权重损失产生，不能把采样权重本身形成的噪声再次反馈为收益。

公式 10

$$\delta_i = (v_i^{old} - v_i^{new})/\max(1, t-t_i), \quad a_i = \exp[-(t-t_i)/K], \quad g_i \leftarrow a_i g_i + (1-a_i)\delta_i$$

按经过的优化更新数归一化，并使用同一时间尺度的 EMA 衰减。

默认K=200个优化器更新。按真实间隔衰减减少一种刷新时间尺度差异，但不能消除自适应观测或未观测偏差，仍须检查年龄与观测次数分组。时间单位固定为optimizer update，不能混用微批或epoch。归一化后的下降仍可能包含其他样本训练产生的迁移效应，因此称“观测收益速率”，不称该样本独有的边际收益。

公式 11

$$\tilde{g}_i = g_i \exp[-(t-t_i)/K], \quad u_i = \mathrm{clip}\left(\frac{\tilde{g}_i - \mathrm{median}(\tilde{g})}{1.4826\mathrm{MAD}(\tilde{g}) + 10^{-8}}, -3, 3\right)$$

陈旧收益向零衰减；只对至少有两次观测的记录计算稳健尺度。

median/MAD严格只在O_t={i:k_i≥2}上计算，不包含尚无两次观测的零占位项；然后对O_t中的记录标准化，其他记录用u_i=0。O_t为空或其MAD为零时全部u_i=0。年龄衰减tilde_g_i只读地由持久g_i和last_step派生；刷新不得原地写回g_i，否则反复刷新及下次观测会重复衰减。每200个更新重建q。首个5% token预算使用r作warmup并计入预算；第二次观测不足时保持参考分布，不额外跑教师。

另记录各频次组的评分刷新年龄、收益分布和观测次数，检查“高收益”是否仅因更新鲜或更短。若偏差明显，先报告并用预注册的同长度桶稳健标准化作敏感性对照；不在看到测试结果后自由切换评分定义。模型遗忘会使 δ_i<0；主方法保留负速率，不通过只截取正下降假装所有数据都在进步。

7. 联合课程优化与可行性

每次刷新时求解一个分布问题；覆盖、探索与成本在同一个最终分布中成立，避免规则串接后相互抵消。

公式 12

$$q_t^* = \arg\max_{q\in\Delta_N}\{\langle q, u_t\rangle - \tau \mathrm{KL}(q\|r)\}$$

效用优先选择当前有学习潜力的记录，KL 正则控制偏离参考分布的程度。

公式 13

$$\text{s.t.}\quad Aq \geq b(t),\quad q_i \geq \varepsilon r_i,\quad c^\top q \leq \bar{c}$$

期望覆盖与期望成本约束，预算执行另由训练循环硬限制。

τ 默认0.5。因为r归一化、Ar=f≥b(t)、r≥ε r且cˆTr=平均参考成本，r始终可行。 τ >0、r_i>0时KL严格凸，分布子问题有唯一最优解。若u=0，则目标为-τ KL(q||r)，唯一解恰为r；因此“覆盖独用”在本设计中与静态r等价。B4只作等价性sanity check复用B2，不另分配GPU训练预算。上述均为分布子问题性质，不保证神经网络全局最优。

公式 14

$$q_i = \max\left\{\varepsilon r_i,\ r_i \exp\left(\frac{u_i + (A^\top \lambda)_i - \nu c_i - \alpha}{\tau}\right)\right\}$$

λ_1≥0对应覆盖、 ν ≥0对应成本、 α ∈R负责归一化；KL导数常数吸收入α 。

未来实现采用稀疏矩阵乘法和固定迭代预算的对偶更新，归一化通过α 的一维二分求解；“固定预算”不意味着人为截断对偶后仍保证收敛。成本先除以参考平均成本稳定尺度。每次刷新最多50次迭代，warm-start上次λ 、 ν 、 α ；检查归一化误差1e-6、探索相对误差1e-6、成本相对违反1e-4、覆盖违反max_1[(b_1-(Aq)_1)_+/max(f_1,1/N)]≤1e-3。50次内不达标即回退r，不保证固定次数找到可行近似解。

若出现 NaN、未满足容差或耗时超过两次连续刷新期间训练墙钟的10%，该次使用 r，增加 fallback_count，并记录错误；连续3次失败暂停该实验查因。不得对违反约束的输出简单归一化后继续宣称覆盖成立。预注册可行回退是方法行为的一部分，需报告回退比例。

这里没有执行求解器或新课程实现。对偶形式、容差与回退定义用于后续工程实现和单元检验。是否在48GB机器与完整标签设置下低开销，必须实测 CPU刷新、数据装载与GPU吞吐之后判断。

8. 采样偏差、风险选择与理论声明边界

改变抽样概率本身就改变训练分布；公平比较需要明确是更快优化同一风险，还是有意改变风险。

公式 15

$$\hat{g}_t = \frac{1}{m_t}\sum_{j=1}^{m_t} \frac{\pi_{I_j}}{q_{t,I_j}} \nabla_\theta \ell_{I_j}(\theta_t),\quad I_j \sim q_t$$

有放回抽样按位置/多重集计数；重复ID不能在训练梯度中去重。

在给定历史与当前参数时，只要 q 固定于该次抽样、每条记录均有支持、风险损失的所有标签项均按统一定义计算，上式对 gradR_pi 条件无偏。q 对历史损失的依赖不破坏这一条件；实现时对 q 和重要性权重 stop-gradient，并使用抽样当时的概率。不能在下一次刷新后用新 q 追溯计算旧样本权重。

公式 16

$$\frac{\pi_i}{q_{t,i}} \le \frac{1}{\varepsilon(1-\eta)} = 10 \quad (\pi_i = 1/N,\ \varepsilon = 0.2, \eta = 0.5)$$

探索和自然分量共同提供有限权重上界，无需主实验中的额外裁剪。

主实验不对重要性权重裁剪、不做批内自归一化，避免隐式偏差。若梯度方差仍不可接受，先提高 ε 或降低 η，并用相同超参网格比较；裁剪或 self-normalized 版本仅作明确标注的偏差-方差消融。有效样本量 ESS=(Σw)^2/Σw²、最大权重与梯度范数必须记录。

忠实原TACL阶段硬遮罩会令部分q_i=0，因而不能在这些阶段用π/q恢复全训练集的自然风险。忠实TACL保留原行为、单独报告。主表的TACL对照明确命名TACL+exploration+IS adaptation：以阶段内归一化分布p_stage构造最终q=εr+(1-ε)p_stage，再用π/q；空阶段回退r。该适配不是原论文原样复现，必须分别报告忠实与适配结果。

重要性校正意味着尾标签被更多曝光并不等于尾标签风险权重更大。预期优势来自有限预算下的优化效率和方差控制，而不是宣称改变了全局最优风险。额外重平衡目标可设 π=r，但必须让自然采样、TACL和联合课程都优化同一 π 后再比较；π=r 的结果不能与 π=uniform 的结果混入同一主表。

给定 t 的 Aq≥b(t) 是条件期望覆盖，而实际 E_l 是随机量。有限 token 停止、mini-batch 组装、模型损失非平稳与陈旧评分使简单独立同分布置信界不直接适用。本轮只主张可行性与单次梯度性质；若后续写覆盖高概率界，须明确适应性鞅条件与随机终止规则。不要把债务减少自动推导为宏F1提高。

mini-batch 内的长度排序只允许重排已经按 q 抽到的记录，不能丢弃或额外替换记录；梯度累积按抽样记录数求均值。若未来使用无放回抽样，当前 π/q 公式不再自动适用，须重新定义包含概率。

9. 伪码、接口、日志与 checkpoint

接口按任务无关的采样状态设计；模型、标签预测与评价保留在原任务适配层。

```
Input: train manifest, sparse A, costs c, model, seed, token budget B
Build r, f=A r, base b0=kappa*f, reference cost cbar; q=r
Initialize per-record last_loss,last_step,gain,count; exposure E=0; S=0
while remaining_tokens >= max(c):
choose m_t=min(16,floor(remaining_tokens/max(c))) BEFORE any batch draw
if warmup completed and optimizer_step % refresh_steps == 0:
derive age-decayed gains READ-ONLY; median/MAD on count>=2 subset -> u
debt=max(S*b0-E,0); target=min(f,b0+debt/H)
solve constrained KL distribution; verify final q; fallback r on failure
draw EXACTLY m_t independent positions WITH replacement from q; store q/version
run microbatches; compute full per-draw risk loss and detached score
backprop sum((pi/q_draw)*risk_loss)/m_t; accumulate and optimizer-step
```

```
merge same-step duplicate-ID SCORES only; update elapsed-normalized EMA
E += positive labels for EVERY consumed draw, including duplicates; S += m_t
tokens += sum exact chunk costs; save token/checkpoint/evaluation events
Select checkpoint and thresholds by development data; evaluate frozen test once
```

接口/对象	最小输入或状态	输出/约束
TaskAdapter	sample_id；group_id；positive_label_ids；encoded_cost；model loss	per-record risk loss 与 detached score；不读取其他数据划分
CurriculumState	reference r；EMA状态；曝光E；累计S；剩余token；solver状态	sample(index,draw_probability,policy_version)
observe(batch)	实际消费ID；抽样时概率；pre-update score；optimizer_step	更新EMA、曝光与预算；同一step重复ID合并评分
refresh()	当前utility；动态目标；成本；可行参考	最终q及归一化/探索/覆盖/成本残差；可行回退标志
state_dict/load_state_dict	schema_version；数据哈希；label_order；RNG状态	恢复同一采样轨迹；哈希或标签序列变化即拒绝恢复

checkpoint 除模型与优化器外，保存 scheduler、AMP scaler、Python/NumPy/torch/CUDA RNG、token消耗、梯度累积余量、样本顺序哈希、标签词表哈希、r与q、policy_version、last_loss/last_step/gain/count、E/S、对偶变量和回退计数。保存于优化器更新边界；若支持中途微批恢复，必须保存尚未提交的梯度与采样队列，否则仅宣称更新边界可复现。

每次刷新日志记录：编码token/实际墙钟/显存峰值、utility分位点、年龄分位点、各频次组正例曝光、归一化覆盖债务、ESS与最大权重、求解器迭代/耗时/残差、回退事件。日志只使用ID与统计，不写完整病历文本。评价输出另有预测分数、标签序列、全局阈值及数据划分哈希，保证可复算。

建议未来新增 task-independent curriculum 模块与独立配置，不在多个 run_* 脚本分别复制算法。此处只定义接口契约；具体路径由实施阶段根据整理后的仓库布局确定。算法变更、训练、联网模型获取与数据许可均不属于本轮文档交付的已执行事项。

10. 单卡48GB资源路径与复杂度

先用可控骨干建立机制证据；任何显存或时间数字都分为文献设置、规划估计与本机实测三类。

首轮英文使用项目PLM-ICD配置中的RoBERTa-base-PM-M3-Voc-distill-align-hf及标签注意力头，C=128、T_max=4096；ICD各采样方法完全一致。采用bf16（硬件不支持则fp16）、微批1、梯度累积16；开启梯度检查点，关闭训练中无关图形输出。TCM使用既有中文领域编码器与148类CE预测头，T_max=512，微批由相同有效记录批大小16约束。实际本地权重及tokenizer版本以文件哈希在运行清单冻结。上述是48GB规划起点，不是显存适配已验证。

如首轮配置OOM，统一减小所有方法的截断上限至2048或分块长度至64，只在开发前置试验确定一次，并报告失去的证据覆盖。不能为新方法截断更多文本而单独为基线保留长文本，或在比较后将此配置差异解释为效率优势。第二阶段扩展8192仅作为输入长度敏感性，不与4096主表混合。

公式 17

$$\text{state memory} = O(N + L + \text{nnz}(A)), \quad \text{refresh work} = O(J[N + \text{nnz}(A)])$$

J为对偶迭代数；不构造N×L的稠密样本-标签状态。

每样本保存少数float32/int64数组，稀疏A可用CSR/CSC两种视图；全局q与参考r保留CPU，抽样索引传入GPU。以N=5万、平均每记录10个正标签为量级例，状态应在几十MB级，而不是把所有标签损失历史保存在GPU。该量级是按数组规模估算，不是实测；最终记录进程RSS、CPU刷新耗时、加载等待及GPU allocated/reserved峰值。

在标准训练前向中读取detached损失，不增加教师模型或全量打分。刷新默认200个优化器更新，J最多50。若CPU投影成为瓶颈，先降低刷新频率或利用稀疏对偶warm-start；所有更改记录在配置中，并保留原默认实验结果。不得把CPU瓶颈排除出方法总墙钟。

后续先用500个更新的授权数据试点测吞吐v（编码token/秒）、峰值显存和刷新占比，估计单次运行时间T≈B/v+预处理与评价成本。全部矩阵资源估计按实际运行数、种子和共同检查点展开，不把25%/50%检查点重复计成独立训练。只有获得试点实测后才能提供GPU小时或日历工期；本方案没有编造速度、GPU小时或本机通过结论。

来源	可核实资源设置	本项目的处理
GKI-ICD	论文H20 96GB；8192 tokens；原文+guideline双路训练。	备选增强；不承诺48GB原样复现。
MSAM/校准论文	论文A100 80GB，分块训练长度受硬件限制。	借鉴评价和长文本处理；不将其完整资源设置当本机基线。
2026证据学习	70B AWQ约40GB只是权重/相关内存量级；完整设置用A100 80GB。	首轮不加载70B；后续可复用获准证据或小模型。
本文联合课程	CPU稀疏状态与正常训练损失；没有GPU实测。	以48GB显存峰值、刷新占比和总墙钟的实测决定是否继续。

11. 预注册实验矩阵与公平比较

先回答单一机制问题，再扩展知识；主表每一行必须有统一风险、骨干、长度、优化器和预算。

方法族	保留的因素	控制的替代解释
B0自然随机	uniform有放回抽样；自然经验风险	最基本训练表现；同token预算与同模型。
B1同风险TACL适配	原阶段策略+探索全支持+IS；忠实原TACL单表	同风险主表可比较；不能把适配称作原样复现。

方法族	保留的因素	控制的替代解释
B2静态参考r	相同尾标签参考分布；π/q校正	效果是否仅来自重平衡采样。
B3收益独用	EMA收益、KL参考、相同探索与成本；移除Aq约束	收益是否导致尾标签饥饿。
B4等价性sanity	u=0时q=r；与B2相同，直接复用B2结果和预算	核对求解器，不作为独立训练或独立方法。
B5收益+固定覆盖	与B6同utility、参考和成本，但始终使用b0=κAr	动态债务修复是否超出固定覆盖约束。
B6完整联合	EMA收益+债务约束+探索+成本；同一π	验证耦合机制。
B7损失/相关课程	ASL或DBL；HiCu；SPMLD思想适配	不是一般长尾损失或已知课程的重复。
IB：InfoBatch适配	近期低loss随机裁剪思想+同风险π/q；原版重标定不叠乘	区分新覆盖约束与已有动态裁剪/梯度校正。

B0/B1/B2/B3/B5/B6先在完整ICD上跑B25/B50/B100检查点，首种子13；无失败后补17和23。B4只核对u=0输出r并复用B2，不新增训练。B1是TACL+exploration+IS adaptation；忠实原TACL作为另行标记的fidelity行。若无可靠原入口，记录复现失败而非替换为未核验变体。所有检查点来自连续训练，不重复计训练预算。

主超参固定采用η=0.5、ε=0.2、κ=0.8、τ=0.5、K=200、refresh=200、warmup=5%。只在开发集作少量敏感性：ε∈{0.1,0.2,0.4}、κ∈{0.5,0.8,1.0}、τ∈{0.2,0.5,1.0}，采用单因素变化，不穷举27组。候选配置的调参token与墙钟单独计入总项目资源。

完整ICD主矩阵通过后，TCM运行B0/B1/B2/B3/B6与忠实TACL行，三种子、B50/B100；B4等价检查复用B2。若ICD显示债务修复有明确增量，再补TCM的B5固定覆盖对照，不重新设计课程。TCM各方法统一CE与最大长度。再入院仅为可选外推。

现代强骨干/方法对照优先PLM-ICD或现有PLM标签注意力头；HiCu需本体且会改变输出任务，因此为ICD专项对照。SPMLD原始算法是矩阵/相关性模型：深度骨干上的多样性正则版本必须命名为adaptation，并以原文正则和超参作为来源。ADO与Data Agent可先作机制对照：前者域级学习潜力，后者训练策略网络；移植不完整时必须标注，不能把简化实现当作者官方结果。

相关证据 [8]、[5]、[4]、[15]、[16]

必须加入InfoBatch-style same-risk adaptation：缓存最近一次未加权逐记录risk loss，未观测初始化为1；每200更新令低于全体缓存均值的记录保留分数$h_i=0.5$，其余$h_i=1$，定义$q_i=h_i/\Sigma_j h_j$；用相同有放回抽样及严格π_i/q_i训练。首5% token均匀warmup，最后12.5% token恢复q=uniform，全部计预算。该版本保留作者低loss软裁剪及末期全量思想，但改变原逐epoch裁剪、$1/(1-\rho)$重标定与迭代次数协议，明确不是完整原版复现。不得把作者重标定系数与π/q叠乘。

相关证据 [21]

InfoBatch适配与B6共享骨干、风险、长度及总token上限，记录评分/阈值刷新/预处理成本与完整墙钟，不以裁剪比例代替实际节省。可选BLS代理行只替换InfoBatch分数：每个有效批的未加权平均risk loss更新参与样本的EMA， α=0.9为本项目设计默认值，其余调度与预算不变；这不是作者超参已在医疗验证的声明。该行在核心主表后开展。

相关证据 [22]

长文本敏感性在B0/B6上比较512、2048、4096，允许时再加8192。B5把b(t)固定为b0，用于债务消融； κ=1时b0=f且b(t)=f，B5/B6理应退化为同一策略，作为端点sanity。分别移除探索、IS与成本上界； ε=0取消权重界，只作受控失败案例。B3已经以固定r作KL锚点，不再重复定义含义重叠的“EMA+静态频次”方法。

12. 指标、统计、不确定性与OOD

主要终点事先确定；阈值、校准与分组规则在开发阶段冻结。

主终点是完整ICD设置B50时的macro-F1；micro-F1为不得明显退化的护栏。辅助报告micro/macro-AUPRC、AUROC、P@8/P@15（Full）或P@5（Top50）、训练频次分组macro-F1、按文本长度分组结果。测试中无正例的标签对AUROC不可定义，需报告可评价标签数与排除规则；不能把未定义项写成0后直接平均。

频次组完全由训练数据确定：tail为1-10，middle为11-100，head为>100；可另给频次分位数组，但不能依据测试表现重划组。仅训练集无正例的标签另列zero-shot/unseen，不计入训练覆盖承诺。TCM单标签同时报告accuracy、macro-F1和各证候召回；多标签则沿用ICD定义。

公式 18

$$\mathrm{DebtRate}(S)=\frac{1}{L}\sum_{l}\frac{D_l(S)}{Sb_l^0+1}$$

同时报告tail子集DebtRate与零曝光标签数，避免少数高频标签掩盖不足。

主要覆盖指标为tail DebtRate、累计零曝光标签比例、每标签正例曝光分位点与真实总抽样数；画出对累计编码token的轨迹。另报告采样分布熵、KL(q||r)、ESS和新观测占比，说明方法如何分配预算。大标签的平均正例曝光可很高，却仍遗漏稀有标签，因此不能仅展示平均值。

ICD多标签阈值使用开发集搜索的单一全局阈值，并补0.5结果；不对极少开发正例逐标签拟合。TCM单标签使用softmax argmax，不用0.5或全局二值阈值。概率校准使用独立开发校准子集和单温度；选择/校准子集按组分开。ICD报告Brier、20-bin label-wise ECE/MECE及频次组结果；TCM报告多类Brier/ECE。单温度不改变TCM的argmax及F1，校准改善不能声称提高单标签分类准确率。

相关证据 [11]

统计报告3种子均值和标准差，并对患者/病案组作配对bootstrap 2000次；有患者ID时以患者为重采样单位，无该ID时明确退化为病案级。主终点只检验预先指定的B6与最强同骨干基线；其他多组结果作为探索性分析，并报告多重比较处理或不作显著性结论。三种子不足以精确估计所有训练随机性，不能仅凭bootstrap替代种子重复。

OOD只在有清晰来源/时间字段时做真实跨时间或跨来源评价，并检查训练与测试组互斥。MIMIC-III到MIMIC-IV同时改变医院时期、预处理和代码版本，不能直接称为纯文本分布迁移。中文TCM与英文ICD是跨任务验证，不是零样本跨域推理。

没有真实外部集时，可预注册缩写替换、文本段落删除和轻度拼写扰动，标注为合成鲁棒性。扰动不得改变诊断标签的医学含义；证据段删除可能使标签不可从输入判定，需单独解释而非简单归因模型错误。若报告弃答/风险-覆盖曲线，阈值由开发集固定，不作患者安全或临床部署能力声明。

13. 第二阶段：知识、检索和LLM证据备选

只有核心覆盖-收益假设通过后，才增加一个备选信号；必须保持论文主贡献集中。

知识备选优先GKI-ICD：使用训练正标签的官方描述、同义词和祖先描述，离线缓存固定版本。可比较“仅知识训练正则”和“相同知识一致性作为课程utility”的两条路线，检验知识究竟改进表征还是改进选择。所有guideline只由训练标签合成；验证/测试不读取其真值构造模型输入。原论文训练期知识注入不增加推理分支，但双路训练的token必须计入总预算。

相关证据 [14]

检索备选使用纯文本与官方标签描述的BM25或小型领域双编码器，先报告候选Recall@K，再讨论重排与难度。若正确标签未被召回，任何后续重排都无法恢复它；候选集合本身也是混淆难度来源。MRR需要DRG/CPT/药物等额外编码，不能将其原文结果作为本项目纯文本条件下的公平优劣证据。

相关证据 [12]

证据备选借鉴2026解释研究，分别评价LLM证据的文本跨度合理性与对学生决策的忠实性。只从已授权训练样本抽固定小集离线标注，首批100例、按头中尾及长短分层；由模型输出原文跨度，拒绝无法在原文定位的证据。若需专家审阅或在线模型调用，应在实际实施时获得数据处理授权；本轮没有调用此类服务。

相关证据 [17]

LLM对“难”的打分不能作为真实难度标签直接监督新课程：模型可能受诊断词显式程度、医学知识覆盖或提示风格影响。较稳妥的用途是审计高债务/低收益群体是否为噪声或证据缺失；保留“复杂但可靠”与“标签可疑”两个维度，不把高损失全当噪声删除。DKEC展示知识可增强小模型少样本分类，MedCodER展示抽取-检索-重排组合，但二者都不能替代本项目的同骨干因果消融。

相关证据 [13]、[19]

中文ICD可考虑ToT-ICD的Code4Detail作额外验证，但它只有560篇、侧重常见病且进行了叙事重构，不适合作本项目长尾训练主证据。首轮TCM证候任务不因为该数据集可见就更换为另一中文任务。

相关证据 [18]

14. 成功、停止标准和研究交付

先冻结评价口径与失败处理，再运行模型；负结果同样应形成可复算的研究结论。

检查点	继续/成功条件	停止或降级条件
G0数据与复现	划分、标签、成本和数据权限清单完整；B0和原TACL入口可重现。	数据版本不明、患者泄漏、原方法入口不可定位时停止算法优劣结论。
G1工程可行	所有概率有限；约束残差达标；恢复后采样轨迹一致；48GB配置可跑。	连续3次投影失败、预算超支、OOM或权重异常即暂停查因。

检查点	继续/成功条件	停止或降级条件
G2核心效应	B50下B6较最强同骨干基线macro-F1绝对提高≥0.01，配对CI下界>0；micro-F1下降不超过0.005。	三种子效果不稳定或改进只能来自目标风险改变，则判H1未支持。
G3机制支持	tail DebtRate相对收益独用降低≥20%；完整方法较B2静态r与B5固定覆盖有增量；B4只检验等价。	若B6与B5无差异则不声称动态债务增量；覆盖改善而F1不变只报告分配机制。
G4效率	总墙钟新增开销≤10%，或达到基线分数所需总墙钟更少；所有离线成本计入。	等token赢分但墙钟明显变差时不声称加速，单独报告精度-成本权衡。
G5跨任务	TCM三种子方向一致，macro-F1平均改进且无明显micro/accuracy退化。	需要任务特制课程才有效，缩小结论至ICD，不追加任务掩盖。

这些阈值为预注册默认值，不是已达到的承诺。如需修改，须在正式主实验和测试访问前依据开发试验统一修改并留版本；不能事后改门槛。预算缩减优先保留B0/B1/B2/B3/B5/B6及3种子；B4复用B2、不占额外GPU。减少知识增强和长度网格。

若H1失败，按顺序排查：EMA刷新年龄偏差、重要性权重方差、覆盖目标过强、共现导致重复曝光、标签噪声与文本截断。只允许一个预注册修订周期：提高探索或降低 κ ，开发集选择后重新冻结。仍失败则交付负结果与诊断，停止追加架构。未经主线通过不开展全量LLM知识生成。

- 本研究资料工作已交付：22篇一手文献索引及BibTeX、结构化中文研究正文、实验矩阵、实现检查清单。
- 本研究资料工作未执行：新课程源码、GPU训练、模型或受限数据下载、性能与显存实测、云端临床文本处理；主任务的仓库重构另有记录。
- 后续代码交付要求：稀疏状态、可行回退、抽样时概率、预算计数与恢复一致性；配套简小合成数据测试，不用受限数据作工程测试。
- 后续研究交付要求：冻结配置与数据哈希、逐种子结果、预算曲线、覆盖债务轨迹、统计区间、失败日志和可复算预测。

附录 默认配置表（研究设计值）

参数	默认值	解释
风险 π	1/N	主实验自然经验风险；平衡风险另表
η / ε / κ / τ	0.5 / 0.2 / 0.8 / 0.5	参考混合/探索/覆盖基础比/熵温度
EMA K / refresh	200 / 200更新	按优化器更新计时
warmup	总token预算的5%	按r抽样；计入总预算
修复H	N次记录抽样	动态需求上限f确保可行
chunk/maxlength	128/4096 ICD；512 TCM	相同任务全部方法一致；48GB待实测
有效batch	16记录	微批1+累积16起步
种子	13,17,23	先13试点，再补重复
B100	10×训练集编码token之和	25/50/100%检查点来自同一次训练

附录 证据和结果状态约定

文献索引中的“已发表”指正式会议/出版社页面或明确作者终稿证据；访问验证页、404与未找到代码均单独注明。表中的资源设置来自文献，不是本项目资源实测。研究正文中的方程、默认值、成功阈值均为待实现规格。本轮没有执行任何模型性能实验。

参考文献

[1] Mucheng Ren; Yucheng Yan; He Chen; Danqing Hu; Jun Xu; Xian Zeng. TACL: Threshold-Adaptive Curriculum Learning Strategy for Enhancing Medical Text Understanding. 2025. BIBM 2025 Regular，作者 camera-ready v2 确认；IEEE落地页本次触发验证页.

https://arxiv.org/abs/2510.15269

[2] Alex Graves; Marc G. Bellemare; Jacob Menick; Rémi Munos; Koray Kavukcuoglu. Automated Curriculum Learning for Neural Networks. 2017. 已发表：ICML 2017.

https://proceedings.mlr.press/v70/graves17a.html

[3] Yiru Wang; Weihao Gan; Jie Yang; Wei Wu; Junjie Yan. Dynamic Curriculum Learning for Imbalanced Data Classification. 2019. 已发表：ICCV 2019.

https://openaccess.thecvf.com/content_ICCV_2019/html/Wang_Dynamic_Curriculum_Learning_for_Imbalanced_Data_Classification_ICCV_2019_paper.html

[4] Seyed Amjad Seyedi; S. Siamak Ghodsi; Fardin Akhlaghian; Mahdi Jalili; Parham Moradi. Self-Paced Multi-Label Learning with Diversity. 2019. 已发表：ACML 2019.

https://proceedings.mlr.press/v101/seyedi19a.html

[5] Weiming Ren; Ruijing Zeng; Tongzi Wu; Tianshu Zhu; Rahul G. Krishnan. HiCu: Leveraging Hierarchy for Curriculum Learning in Automated ICD Coding. 2022. 已发表：MLHC 2022.

https://proceedings.mlr.press/v182/ren22a.html

[6] Tong Wu; Qingqiu Huang; Ziwei Liu; Yu Wang; Dahua Lin. Distribution-Balanced Loss for Multi-Label Classification in Long-Tailed Datasets. 2020. 已发表：ECCV 2020.

https://www.ecva.net/papers/eccv_2020/papers_ECCV/html/1631_ECCV_2020_paper.php

[7] Tal Ridnik; Emanuel Ben-Baruch; Nadav Zamir; Asaf Noy; Itamar Friedman; Matan Protter; Lihi Zelnik-Manor. Asymmetric Loss for Multi-Label Classification. 2021. 已发表：ICCV 2021.

https://openaccess.thecvf.com/content/ICCV2021/html/Ridnik_Asymmetric_Loss_for_Multi-Label_Classification_ICCV_2021_paper.html

[8] Chao-Wei Huang; Shang-Chi Tsai; Yun-Nung Chen. PLM-ICD: Automatic ICD Coding with Pretrained Language Models. 2022. 已发表：ClinicalNLP 2022.

https://aclanthology.org/2022.clinicalnlp-1.2/

[9] Joakim Edin; Alexander Junge; Jakob D. Havtorn; Lasse Borgholt; Maria Maistro; Tuukka Ruotsalo; Lars Maaløe. Automated Medical Coding on MIMIC-III and MIMIC-IV: A Critical Review and Replicability Study. 2023. 已发表：SIGIR 2023.

https://arxiv.org/abs/2304.10909

[10] Junyu Luo; Xiaochen Wang; Jiaqi Wang; Aofei Chang; Yaqing Wang; Fenglong Ma. CoRelation: Boosting Automatic ICD Coding through Contextualized Code Relation Learning. 2024. 已发表：LREC-COLING 2024.

https://aclanthology.org/2024.lrec-main.355/

[11] Goncalo Gomes; Isabel Coutinho; Bruno Martins. Accurate and Well-Calibrated ICD Code Assignment Through Attention Over Diverse Label Embeddings. 2024. 已发表：EACL 2024.

https://aclanthology.org/2024.eacl-long.141/

[12] Xindi Wang; Robert Mercer; Frank Rudzicz. Multi-stage Retrieve and Re-rank Model for Automatic Medical Coding Recommendation. 2024. 已发表：NAACL 2024.

https://aclanthology.org/2024.naacl-long.273/

[13] Xueren Ge; Abhishek Satpathy; Ronald Dean Williams; John Stankovic; Homa Alemzadeh. DKEC: Domain Knowledge Enhanced Multi-Label Classification for Diagnosis Prediction. 2024. 已发表：EMNLP 2024.

https://aclanthology.org/2024.emnlp-main.712/

[14] Xu Zhang; Kun Zhang; Wenxin Ma; Rongsheng Wang; Chenxu Wu; Yingtai Li; S Kevin Zhou. A General Knowledge Injection Framework for ICD Coding. 2025. 已发表：Findings ACL 2025.

https://aclanthology.org/2025.findings-acl.374/

[15] Yiding Jiang; Allan Zhou; Zhili Feng; Sadhika Malladi; J. Zico Kolter. Adaptive Data Optimization: Dynamic Sample Selection with Scaling Laws. 2025. 已发表：ICLR 2025；首次arXiv为2024.

https://proceedings.iclr.cc/paper_files/paper/2025/hash/923285deb805c3e14e1aeebc9854d644-Abstract-Conference.html

[16] Suorong Yang; Fangjian Su; Hai Gan; Ziqi Ye; Jie Li; Baile Xu; Furao Shen; Soujanya Poria. Data Agent: Learning to Select Data via End-to-End Dynamic Optimization. 2026. 已发表：ICML 2026.

https://proceedings.mlr.press/v306/yang26bq.html

[17] Mingyang Li; Viktor Schlegel; Tingting Mu; Wuraola Oyewusi; Kai Kang; Goran Nenadic. Evaluation and LLM-Guided Learning of ICD Coding Rationales. 2026. 已发表：EACL 2026.

https://aclanthology.org/2026.eacl-long.232/

[18] Xinjie Xu; Yongqi Fan; Shuang-shuang Chen; Qi Ye; Weibin Guo; Xinxuan Hu. Travel on the ICD Tree: Benchmarking Agentic Reasoning for ICD Coding from Chinese Electronic Medical Records. 2026. 已发表：Findings ACL 2026.

https://aclanthology.org/2026.findings-acl.191/

[19] Krishanu Das Baksi; Elijah Soba; John J Higgins; Ravi Saini; Jaden Wood; Jane Cook; Jack I Scott; Nirmala Pudota; Tim Weninger; Edward Bowen; Sanmitra Bhattacharya. MedCodER: A Generative AI Assistant for Medical Coding. 2025. 已发表：NAACL 2025 Industry.

https://aclanthology.org/2025.naacl-industry.37/

[20] Canran Xiao; Chuangxin Zhao; Zong Ke; Fei Shen. Curiosity Meets Cooperation: A Game-Theoretic Approach to Long-Tail Multi-Label Learning. 2025. arXiv预印本；未核实正式发表，HTML的Journal字样不足以确认录用.

https://arxiv.org/abs/2510.17520

[21] Ziheng Qin; Kai Wang; Zangwei Zheng; Jianyang Gu; Xiangyu Peng; Zhaopan Xu; Daquan Zhou; Lei Shang; Baigui Sun; Xuansong Xie; Yang You. InfoBatch: Lossless Training Speed Up by Unbiased Dynamic Data Pruning. 2024. 已发表：ICLR 2024.

https://proceedings.iclr.cc/paper_files/paper/2024/hash/ad1d7a4df30a9c0c46b387815a774a84-Abstract-Conference.html

[22] Qing Zhou; Bingxuan Zhao; Tao Yang; Hongyuan Zhang; Junyu Gao; Qi Wang. Batch Loss Score for Dynamic Data Pruning. 2026. 作者arXiv Comments注明CVPR2026 accepted；本次未独立核实CVF正式收录页.

https://arxiv.org/abs/2604.04681

配套文件

outputs/research/literature.csv：22篇文献的机制、状态、代码、资源与证据定位。

references.bib：可导入文献管理工具的条目。

experiment_matrix.csv：分阶段实验、预算与决策门槛。

implementation_checklist.csv：数据、基线、调度、评估及复现实施项。

research_content.json：本方案可编辑结构化正文。